

M24 Statistik 1: Wintersemester 2024 / 2025

Vorlesung 01: Einführung

Prof. Matthias Guggenmos

Health and Medical University Potsdam



Grit

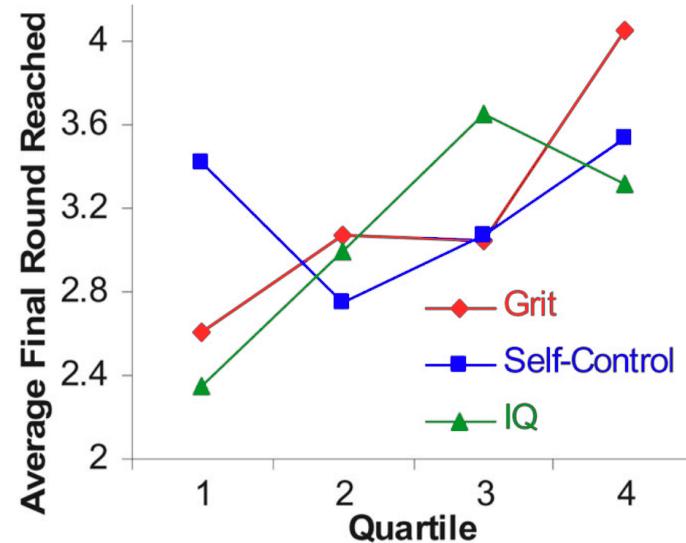


Grit: The Power of Passion and Perseverance | Angela Lee Duckworth | TED

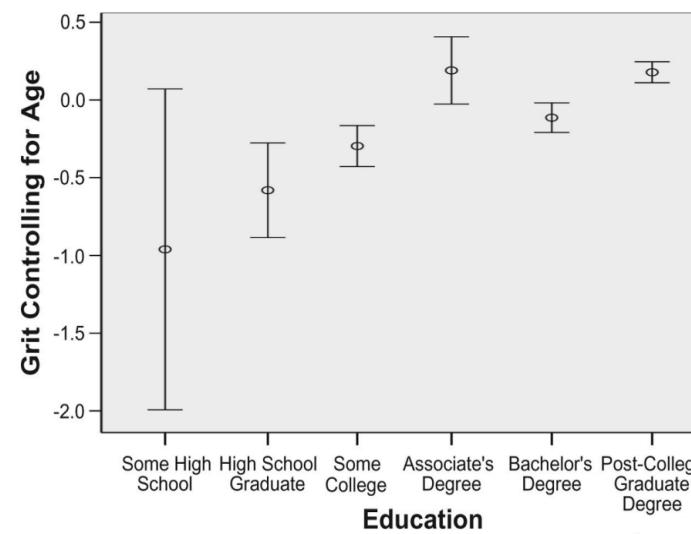


youtu.be/H14bBuluwB8

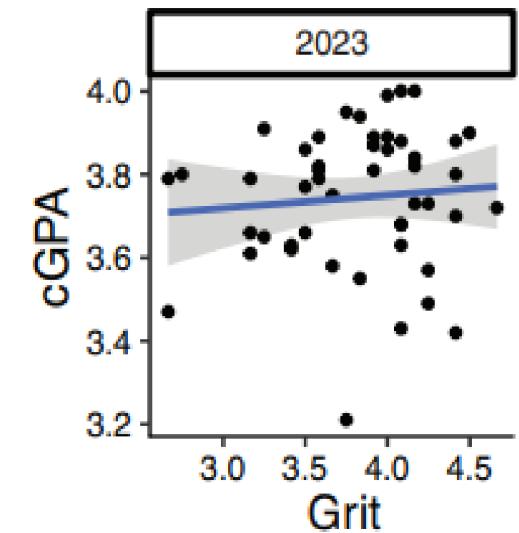
Statistik 1 & 2: Ziele



Quelle¹



Quelle²



Quelle³

- Wissenschaftliche Ergebnisse **verstehen** und **kritisch hinterfragen**
- Statistische Analysen **selbst durchführen**

Anwesenheitsliste

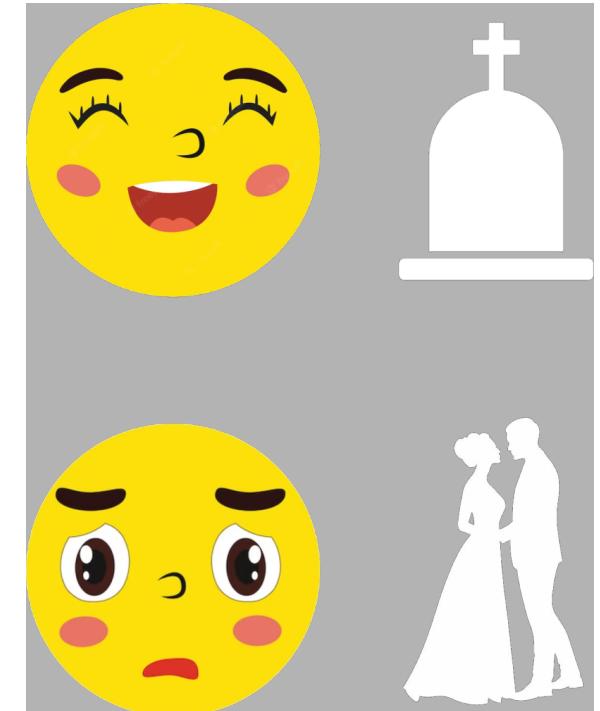


Paradoxa

Eine rätselhafte Erkrankung


Eine rätselhafte Erkrankung hat seit geraumer Zeit die Bundesrepublik Deutschland heimgesucht. Die Betroffenen zeigen ein paradoxes emotionales Verhalten: sie reagieren allem Anschein nach traurig auf fröhliche Ereignisse und fröhlich auf traurige Ereignisse – als wären zwei Hirndrähte vertauscht worden!

Aufgrund ihres Erscheinungsbilds wird die neuartige Krankheit Paradoxia genannt.



Weiteres Mysterium: blaue Haare

Noch ist wenig bekannt über die Erkrankung. Eine weitere Auffälligkeit ist, dass viele der Betroffenen eine Neigung haben, ihre Haare blau zu färben. Warum das so ist, ist unklar, auch wenn gemutmaßt wird, dass hierfür ein viral gegangenes Tik-Tok-Video einer Betroffenen verantwortlich ist.



Task Force

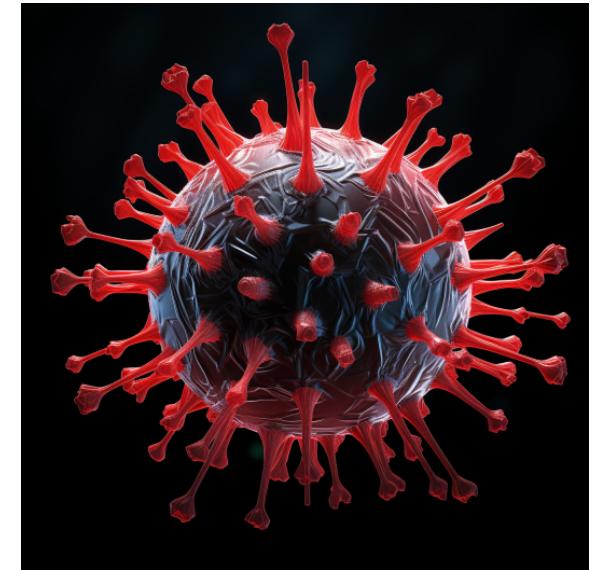
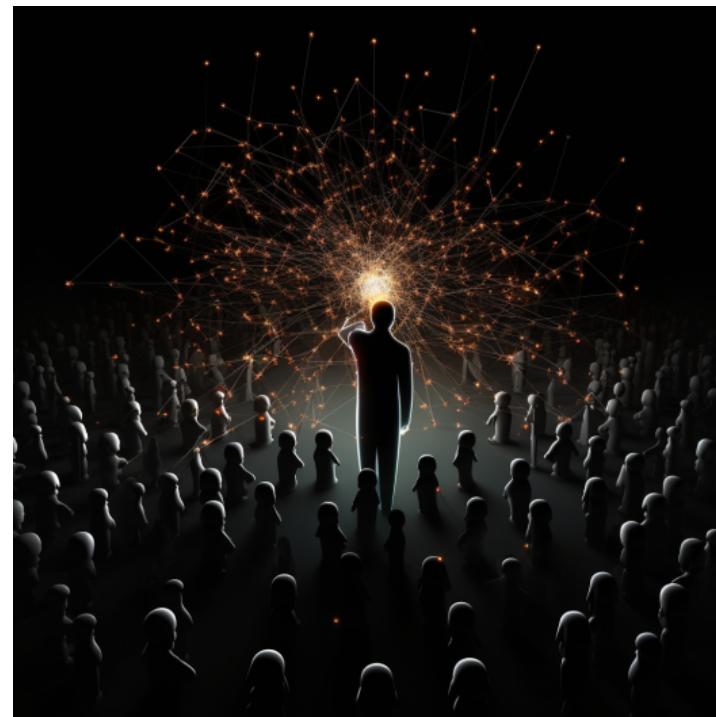
Durch die rapide Verbreitung der Erkrankung sind das Bundeskanzleramt und die Geheimdienste alarmiert. Schnell wird der Beschluss gefasst, eine Task Force bestehend aus Psycholog:innen, Mediziner:innen und Sozialforscher:innen ins Leben zu rufen, um die Erkrankung besser zu verstehen.



Sie sind Teil dieser Task Force im **Team Psychologie**.

Eine erste Aufgabe: Hypothesenbildung

Ihre erste Aufgabe besteht darin, **Hypothesen** zu bilden, wie es zum Auftreten der Erkrankung gekommen sein könnte. Vermutet wird entweder ein **sozialpsychologisches Ansteckungsphänomen** oder eine **neuartige Viruserkrankung**, die das zentrale Nervensystem befällt.



Aber zunächst: Formalitäten

Anwesenheits- und Fehlzeitregelung

§ 8

Anwesenheits- und Fehlzeitenregelung

- (1) Die nachfolgenden Anwesenheits-/Fehlzeitenregelungen gelten für alle Präsenzveranstaltungen. Für die Abwesenheit im Praktikum bestehen Regelungen in der jeweiligen Praktikumsordnung. Für die Abwesenheit/Fehlzeiten an Prüfungen/Prüfungstagen gelten vorrangig die Regelungen zum Rücktritt von Prüfungen nach der Rahmenprüfungsordnung oder den Studien- und Prüfungsordnungen der Studiengänge.
- (2) Die HMU ist eine Präsenzuniversität, damit besteht 100% Präsenzpflicht unter Beachtung der jeweiligen Studiengangmodelle (Vollzeitstudium, Teilzeitstudium). Pro Modul im Vollzeitmodell darf die Fehlzeit nicht mehr als 40% betragen, im Teilzeitmodell beträgt die maximale Fehlzeit 20% pro Modul. Im Studiengang Humanmedizin, im Bachelorstudiengang Psychologie und im Masterstudiengang Psychotherapie gilt ein Modul nur als regelmäßig besucht, wenn die Studierenden bei 80 % der Lehrveranstaltungen anwesend waren. Das gilt auch für virtuelle Präsenzlehrveranstaltungen. Sollte diese Fehlzeit von Studierenden überschritten werden, entscheidet der Lehrende über die Zulassung zur Prüfung. In

Bildnachweis⁴

Nützliche Links

Statistik für Psychologie	https://www.statistikpsychologie.de/blog/	Einige nützliche Blogeinträge zu statistischen Themen der Psychologie
DATAtab	https://datatab.de/tutorial/	Online-Kalkulator mit einigen guten Tutorials
StatistikGuru	https://statistikguru.de/	Fokus auf SPSS und R, aber viele Tutorials in allgemeinem Stil geschrieben
Statistics Supreme with JASP	https://www.youtube.com/@StatisticsSupreme	YouTube-Kanal zu JASP des Kollegen Thomas Langkamp (MSH)
Statistik 1 Vorlesungen auf YouTube	https://www.youtube.com/playlist?list=PLU-U4gWcFfPxmKviyopGSmOY2EaKLVYxF	Prof. Jonas Obleser (Uni Lübeck)

Vorlesungsfolien

Trainex

The screenshot shows the Trainex platform interface. On the left is a sidebar with links: Anwesenheiten, Archive, E-Learning, Glossar, Hausaufgaben, Laufwerk, and Bibliothek. The main content area displays course materials for "Statistik I, II". Under "Statistik I", there is a link to "Feinplanung (PDF, 61 KB)" which is marked as "Neu". Other visible links include "Akademischer Terminkalender Medizin (PDF)", "Akademischer Terminkalender BA/ MA (PDF)", and "Einführung in den Bachelor Psychologie (PDF)".

Format: pdf

trainex25.de/hmu-trainex

Webseite

The screenshot shows a web browser window with the title "Vorlesung 01: Intro - Chromium". The address bar shows the URL "hmu-stats.github.io/01_intro/_slides/index.html#/" and the page number "1 / 30". The content of the slide is titled "M24 Statistik 1" and "Vorlesung 01: Intro". It features a photo of a group of people and the text "Prof. Matthias Guggenmos Health and Medical University Potsdam". At the bottom, there are navigation icons for a menu, a document, and a pencil, along with the text "Vorlesung 01: Intro" and the HMU logo.

Format: html & pdf

hmu-stats.github.io

Klausur

- In der vorlesungsfreien Zeit nach Semesterende findet eine **schriftliche Klausur** zu Statistik 1 statt.
- **Klausurrelevant** sind dabei alle **Inhalte der Vorlesungsfolien**, falls nicht extra gekennzeichnet.
- **Klausurrelevant** sind auch die **Übungen**, die Sie im **Seminar** durchführen.



Literatur



Jürgen Bortz & Christof Schuster. *Statistik für Human- und Sozialwissenschaftler*. Springer, 7. Auflage (2010).

Standardwerk. Umfassend, gute Erklärungen, viele Übungen.




Thomas Schäfer. *Methodenlehre und Statistik*. Springer, 1. Auflage (2016).

Nah an der Vorlesung, Inhalte auf das Wesentliche heruntergebrochen.



Michael Eid, Mario Gollwitzer & Manfred Schmitt. *Statistik und Forschungsmethoden*. Beltz, 5. Auflage (2017).

Umfassend, vergleichsweise mathematisch, eher für Fortgeschrittene und weitergehend Interessierte. Enthält nützliche Übungen.



Ron Larson & Betsy Farber. *Elementary Statistics: Picturing the World*. Pearson, 7. Auflage (2019).

Unterhaltsamer intuitiver Stil, kurz & bündig, viele Übungen, auf Englisch!

Taschenrechner

- Ab dem Sommersemester 2024 wird für Statistik 1 & 2 folgender Taschenrechner empfohlen: **Casio fx-87DE PLUS-2**
- Für die Klausur **zulässig** sind folgende Modelle:
 - Casio fx-87*(alle Untermodelle)
 - Casio fx-85*(alle Untermodelle)
 - Casio fx-82*(alle Untermodelle)
 - Casio fx-991*(alle Untermodelle)



Was ist Statistik?

Was ist Statistik?

Das Wort Statistik stammt von lateinisch *statisticum* „den Staat betreffend“ und italienisch *statista* Staatsmann oder Politiker [...]

Quelle: Wikipedia

In diesem Sinne beschrieb der Ausdruck Statistik ursprünglich die Lehre von den Daten über den Staat. Heute ist der Begriff wesentlich breiter gefasst:

Statistik ist ein angewandter Zweig der Mathematik, der sich mit der **Erhebung, Analyse und Interpretation empirischer Daten** befasst.

Beispiele

Erhebung	Wie groß sollte meine Stichprobe sein?
Analyse	Was ist der Mittelwert meiner Variable?
Interpretation	Unterscheiden sich zwei Gruppen systematisch?



Bildnachweis^{5 6}

Wozu Statistik?

Auch ohne Statistik sind Menschen sehr gut darin, Muster oder Zusammenhänge in ihrer Umwelt zu erkennen. Man könnte diese Fähigkeit als **intuitive Empirie** bezeichnen. Wozu also Statistik?

Probleme intuitiver Empirie (kleiner Ausschnitt)

- Kognitive Biases (z.B. Konfirmationsbias)
- Schwächen beim probabilistischen Denken (Stichwort *Lotto*)
- Übergeneralisierung / Tendenz zur vorschnellen Verallgemeinerung
- Übersensitivität: Muster erkennen, wo keine sind
- Vermischung mit eigenen Interessen (z.B. Politik)
- Begrenztes (Arbeits)Gedächtnis: Unfähigkeit, große Datenmengen im Kopf zu behalten und zu verrechnen



Bildnachweis⁷

Beispiel Prävalenzfehler

- Nehmen Sie an, 1% der Bevölkerung sind an Corona erkrankt.
- Ein neu entwickelter Coronatest wird damit beworben, dass er anhand einer Speichelprobe in 100% (!) der Fälle eine bestehende Coronaerkrankung erkennt.
- Im Kleingedruckten findet sich der Hinweis, dass der Test in 10% der Fälle eine gesunde Person fälschlicherweise als krank ausweist.



Schätzen Sie: Angenommen Ihr Test ist positiv — mit welcher Wahrscheinlichkeit sind Sie dann auch tatsächlich an Corona erkrankt?

Beispiel Prävalenzfehler

Auflösung:

- Von 100 Personen ist im Schnitt 1 Person krank. Diese wird durch den Test auf jeden Fall korrekt als krank erkannt.
- 99 Personen sind nicht erkrankt, und bei 10% dieser Personen gibt der Test ein falsch-positives Ergebnis (≈ 10 Personen).
- D.h. bei 100 Personen haben ≈ 11 Personen ein positives Ergebnis, aber bei 10 von 11 Personen (91%) ist dieses Ergebnis falsch!



Unsere empirische Intuition versagt in diesem Fall häufig. Im konkreten Beispiel spricht man auch vom **Prävalenzfehler** oder der **Base rate fallacy**.

Beispiel Meditonsin

Meditonsin ist das meistverkaufte homöopathische Erkältungsmittel in Deutschland, mit einem Jahresumsatz von deutlich über zwanzig Millionen Euro.

Jedenfalls entwickelte ein Chemieprofessor für Medice eine Apparatur, die alle Zutaten von Meditonsin bis heute in 250-Liter-Fässern vermischt und am Ende zehnmal kräftig in Richtung Erdmittelpunkt schüttelt.

Meditonsin enthält laut Beipackzettel Tollkirsche und Eisenhut in D5-Auflösung [0,00001%] sowie Quecksilber in D8-Auflösung [0,00000001%].

Quelle: Süddeutsche Zeitung⁸

DAZ.online

Unabhängige pharmazeutische Informationen für Wissenschaft und Praxis der Deutschen Apotheker Zeitung

RECHTSKRÄFTIGES URTEIL

Meditonsin-Werbung mit Apotheken-Studie unzulässig

BERLIN - 03.05.2023, 14:45 UHR



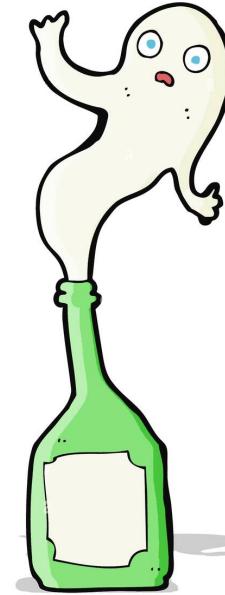
Meditonsin-Hersteller Medice darf für seine homöopathischen Tropfen nicht mehr damit werben, dass in einer „apothekenbasierten Beobachtungsstudie“ die gute Wirksamkeit und Verträglichkeit des Mittels nachgewiesen wurde. Ein entsprechendes Urteil des Landgerichts Dortmund aus dem vergangenen Herbst ist jetzt rechtskräftig geworden. Geklagt hatte die Verbraucherzentrale Nordrhein-Westfalen.

Laut einem Gerichtsurteil aus dem Mai 2023 darf Meditonsin nicht mehr mit einer vorgeblich wissenschaftlich bewiesenen Wirksamkeit werben.⁹

Beispiel Meditonsin

Woher kommt das große Vertrauen in ein Medikament, bei dem eine Flasche im Schnitt kaum ein Molekül der vorgeblichen Wirksubstanzen enthält?

Warum entsteht bei vielen Menschen subjektiv der Eindruck, Medikamente wie Meditonsin würden wirken?

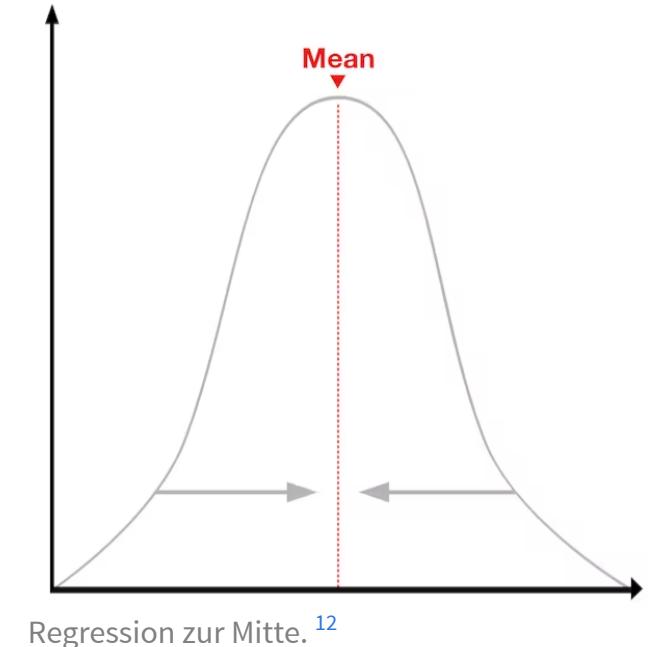


Der Geist in der Flasche.¹⁰

Beispiel Meditonsin

Eine Erklärung ist mangelndes Bewusstsein für einen Effekt, der auch als **Regression zur Mitte** bezeichnet wird.

- Meditonsin wird vermutlich häufig eingenommen, wenn eine Erkältung auf ihrem Höhepunkt ist.
- *In aller Regel verbessert* sich der Gesundheitszustand nach Erkältungen auch ohne Medikation und pendelt sich wieder auf einen Normalzustand ein (dies ist die “Regression” zur “Mitte”).
- Dadurch entsteht eine subjektiv wahrgenommener Zusammenhang Einnahme Meditonsin → Heilung



Statistische Methoden ermöglichen hier in Kombination mit einem adäquaten Studiendesign (Interventions- und Placebogruppe) eine objektivere Einschätzung.

Empfehlung: Quarks Science Podcast “Meditonsin, Umckaloabo, Grippostad: Die Akte Erkältungsmittel”¹¹

Deskriptive Statistik und Inferenzstatistik


In Statistik 1 und 2 werden wir Methoden aus der **deskriptiven Statistik** und **Inferenzstatistik** behandeln.

Das Ziel der **deskriptiven Statistik** ist die Beschreibung und Zusammenfassung von Daten innerhalb einer Stichprobe.

Beispielfragen: Wie hoch ist der Mittelwert einer Variable in der Stichprobe? Wie hoch ist die Korrelation zwischen Variable X und Variable Y in der Stichprobe?

Das Ziel der **Inferenzstatistik** sind Schlussfolgerungen über eine Population auf der Grundlage von Stichproben.

Beispielfragen: Wie groß ist die durchschnittliche Körpergröße der Bevölkerung, basierend auf einer Stichprobe von 500 Personen? Gibt es einen signifikanten Unterschied im durchschnittlichen Einkommen zwischen zwei verschiedenen Berufsgruppen?



Ein alternativer Ausdruck für Inferenzstatistik ist Induktive Statistik.

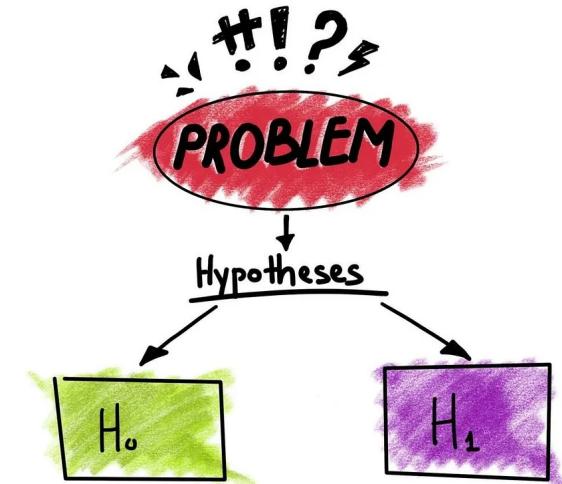
Hypothesen

Was ist eine Hypothese?

Hypothesen: in Form einer logischen Aussage formulierte Annahme zur Erklärung empirischer Phänomene.

Beispiele

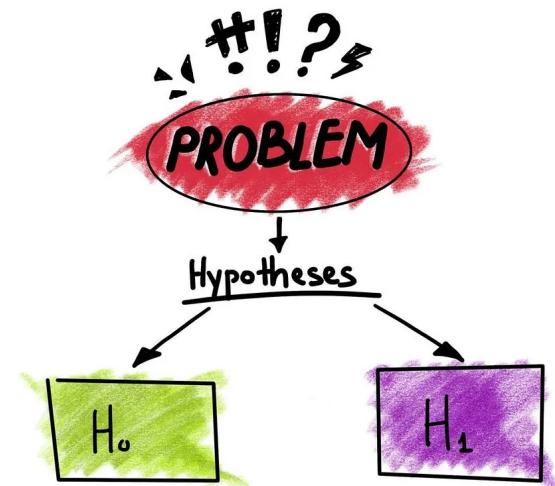
- Es gibt einen positiven Zusammenhang zwischen der Feinstaubbelastung einer Stadt und der Prävalenz von Lungenerkrankungen.
- Eine vorherige Impfung mit dem Corona-Impfstoff verringert die Symptomschwere im Fall einer Infektion.
- Eine wissenschaftliche Hypothese muss **widerlegbar/falsifizierbar** sein; dies impliziert u.a., dass die Hypothese **widerspruchsfrei** ist und **operationalisierbar** ist.



Bildnachweis¹⁴

Warum Hypothesen?

- Eine Hypothese überführt eine **Annahme / Vermutung / Intuition** in eine präzise wissenschaftliche Fragestellung.
- Eine a priori (“vorab”) aufgestellte Hypothese macht **transparent**, was Forscher:innen **vor Durchführung einer Studie** erwartet haben.
 - Andernfalls handelt es sich um HARKing: “Hypothesizing After Results Known” (d.h. die Hypothese wird *im Nachhinein* an die gemessenen Daten angepasst).
- Eine präzise Formulierung der Hypothese kann helfen, die **exakte Fragestellung und Methodik einer Studie** festzulegen.
- Eine präzise Formulierung der Hypothese hilft dabei, einen geeigneten **statistischen Test** auszuwählen.



Bildnachweis¹⁵

Operationalisierung: Messbarmachung eines theoretischen Konstrukts (Schwerkraft, Intelligenz, psychische Resilienz, ...) durch ein geeignetes Messinstrument (Gravimeter, Intelligenztest, Fragebogen, ...)


Gerichtete und ungerichtete Hypothesen

Ungerichtete Hypothesen geben keine Richtung des Effektes an:

- Frauen und Männer haben unterschiedliche viele soziale Kontakte
- Die Punktzahl im Abitur hängt zusammen mit der späteren Lebenszufriedenheit

Gerichtete Hypothesen geben die Richtung des Effektes an:

- Frauen haben *mehr* soziale Kontakte als Männer
- Eine höhere Punktzahl im Abitur korreliert *negativ* mit der späteren Lebenszufriedenheit



Bildnachweis¹⁶

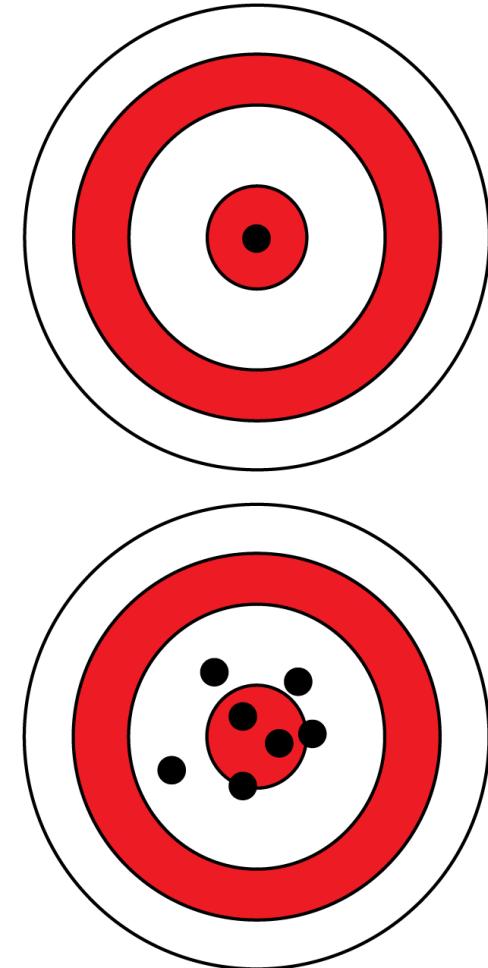
Probabilistische Hypothesen

In der Psychologie sind Hypothesen in aller Regel nicht **deterministisch**, sondern **probabilistisch**, d.h. sie machen Aussagen über Wahrscheinlichkeiten und Mittelwerte.

Beispiel deterministische Hypothese: Menschen mit Alkoholabhängigkeit entwickeln eine Depression.

Beispiel probabilistische Hypothese: Menschen mit Alkoholabhängigkeit haben *im Mittel* eine höhere Ausprägung depressiver Symptome.

- Psychologische Phänomene sind in der Regel von einer Vielzahl von Faktoren beeinflusst, die zum Großteil nicht bekannt sind (biologisch-z.B. Blutdruck, psychologisch-z.B. Stimmung, situativ-z.B. Versuchslabor versus Realität).
- Diese Faktoren erhöhen die Variabilität von Beobachtungen und führen dazu, dass die meisten psychologischen Phänomene nur durch Mittelwertbildung über eine Reihe von Messwiederholungen sichtbar werden.



Bildnachweis¹⁷



Ok, Task Force: wie lauten eure (Arbeits-)Hypothesen zu den Hintergründen von Paradoxa?

Hypothese 1: Die Blaufärbung der Haare ist ein reines Tik-Tok-Phänomen. *Betroffene sollten daher im Mittel mehr Zeit auf der Social-Media-Plattform TikTok verbringen als Nicht-Betroffene.*

Hypothese 2: Paradoxa wird durch eine virale Infektion verursacht. *Die Blutproben von Betroffenen sollten daher im Mittel eine höhere Konzentration von Entzündungsmarkern aufweisen als von Nicht-Betroffenen.*

Notation

Drei Fälle bei der Berechnung statistischer Kennwerte

Fall 1: Populationskennwerte

Vollständige Population liegt vor (z.B. alle US-Präsidenten)

⇒ Bestimmung exakter statistische Kennwerte für die Population

⇒ *Populationskennwerte* (z.B. Populationsstreuung)

(Hinweis: man spricht auch manchmal von Populationsparametern)

Fall 2: Stichprobenkennwerte

Stichprobe liegt vor

⇒ Ziel ist Beschreibung der Stichprobe *ohne Inferenz auf die Population*


⇒ *Stichprobenkennwerte* (z.B. Stichprobenstreuung)

Fall 3: Inferentielle Kennwerte

Stichprobe liegt vor

⇒ Ziel ist *Inferenz auf die Population*, d.h. die Populationskennwerte sollen auf Basis der Stichprobe geschätzt werden.

⇒ *Inferentielle Kennwerte* (z.B. inferentielle Streuung)



Notation / Variablenbenennung

- Folgendes Schema hat sich in der Literatur etabliert:

- **Populationskennwerte**: griechische Buchstaben
- **Stichprobenkennwerte**: lateinische Buchstaben
- **Inferentielle Kennwerte**: griechische Buchstaben mit Zirkumflex (^).

	Populations- Kennwert	Stichproben- Kennwert	Inferentieller Kennwert
Mittelwert	μ	\bar{x}, m, M	$\hat{\mu}$
Standardabweichung	σ	s	$\hat{\sigma}$
Varianz	σ^2	$s^2, Var(X)$	$\hat{\sigma}^2, \hat{Var}(X)$
Kovarianz	σ_{XY}	$s_{XY}, Cov(X, Y)$	$\hat{\sigma}_{XY}, \hat{Cov}(X, Y)$
Korrelation	ρ	r	$\hat{\rho}$

- Grund für die aufwendige Unterscheidung in der Notation:

- Kommunikation des Analyseziels in einer Formel
- Formeln für Populations- und Stichprobenkennwerte sind identisch, die Formeln für inferentielle Kennwerte können jedoch verschieden sein!
- (Ausnahme: beim Mittelwert gilt $\hat{\mu} = \bar{x}$)

Hinweis

Um die Komplexität zu reduzieren, werden wir **in dieser Vorlesungsreihe konsequent Formeln für inferentielle Kennwerte behandeln** (zu erkennen am $\hat{\cdot}$). Dies ist der mit Abstand häufigste Fall in der Psychologie und de facto in allen empirischen Wissenschaften.



In der Literatur (Lehrbücher, Statistikportale, Wikipedia, ...) herrscht ein heilloses Durcheinander bezüglich der Verwendung der Begriffe Populationskennwert (z.B. Populationsvarianz) und Stichprobenkennwert (z.B. Stichprobenvarianz). Beide Begriffe werden zum Teil dafür verwendet, was hier als inferentieller Kennwert bezeichnet wird. Eine Ursache ist, dass sich für das Konzept des "inferentiellen Kennwerts" bislang kein etablierter Begriff herausgebildet hat. Den Begriff "inferentieller Kennwert" werden Sie daher bei Google nicht finden.

Die Lösung dieses Dilemmas in dieser Veranstaltung besteht eben in der Einführung des Begriffs **inferentieller Kennwert**. In dieser Logik beschreibt ein Populationskennwert die Population, ein Stichprobenkennwert beschreibt die Stichprobe, und ein inferentieller Kennwert schätzt die Populationskennwerte auf Basis der Stichprobe ("Inferenz auf die Population").

Fußnoten

1. Duckworth AL, Peterson C, Matthews MD, Kelly DR (2007) Grit: Perseverance and passion for long-term goals. *Journal of Personality and Social Psychology* 92:1087–1101.
2. Duckworth AL, Peterson C, Matthews MD, Kelly DR (2007) Grit: Perseverance and passion for long-term goals. *Journal of Personality and Social Psychology* 92:1087–1101.
- 3.
- Huebner B, Mattocks A, Pitt J (2023) Noncognitive Factors of Grit and Mindset Do Not Predict Performance on the National Physical Therapy Exam. *Journal of Physical Therapy Education* 37:138.
4. Allgemeine Universitätsordnung der HMU
5. <https://www.analyticsinsight.net/importance-of-statistics-how-is-statistics-related-to-data-science/>
6. <https://www.livescience.com/roman-republic>
7. <https://www.arte.tv/de/videos/093029-022-A/flick-flack/>
8. <https://sz-magazin.sueddeutsche.de/gesundheit/meditonsin-wirkung-erkaeltung-globuli-81941>
9. <https://www.astronomy.com/science/in-praise-of-nothing/>
10. <https://www.alamy.de/stockfoto-cartoon-geist-in-der-flasche-72046687.html>
11. <https://www.quarks.de/podcast/quarks-science-cops-folge-48-erkaeltungsmittel-wissenschaft-oder-kruemeltee/>
12. <https://theconversation.com/regression-to-the-mean-or-why-perfection-rarely-lasts-74694>
13. <https://datatab.net/tutorial/descriptive-inferential-statistics>
14. <https://pub.towardsai.net/hypotheses-testing-with-scipy-b5ba86430d74>
15. <https://pub.towardsai.net/hypotheses-testing-with-scipy-b5ba86430d74>
16. <https://datatab.de/tutorial/hypothesen>
17. <https://www.toolsgroup.com/blog/what-is-probabilistic-forecasting/>