

M24 Statistik 1: Wintersemester 2024 / 2025


Vorlesung 05: Regression

Prof. Matthias Guggenmos

Health and Medical University Potsdam




Kurze Erinnerung: beim letzten Mal fanden wir einen Zusammenhang von TikTok-Online-Zeit und Entzündungsparametern:



Bei der Interpretation stellt sich einerseits die Kausalitätsfrage, andererseits, wie stark der Zusammenhang tatsächlich ist. Da die Pearson-Korrelation lediglich den **Grad der Linearität** beurteilt, fragen Sie sich: um wie viel erhöhen sich die Entzündungsparameter pro Stunde zusätzliche Zeit auf TikTok? Oder umgekehrt: um wie viel erhöht sich die Zeit auf TikTok, wenn die Entzündungswerte um einen Wert x ansteigen?


Regression



Bildnachweis¹

Regression



- Dem Wortsinn nach ist Ziel der **Regression** eine abhängige Variable auf eine oder mehrere Prädiktorvariablen zurückzuführen (auf diese zu *regredieren*).
- Eingängiger ist aber die umgekehrte Formulierung: Ziel der Regression ist es, auf Basis der Prädiktorvariablen die abhängige Variable **vorherzusagen** oder **zu erklären**:
 - Prädiktorvariable(n) = *vorhersagende* oder *erklärende* Variable(n).
 - Abhängige Variable = *vorhergesagte* oder *erklärte* Variable.



- Beispiel: Studie untersucht Auswirkung von sportlicher Aktivität auf Lebenszufriedenheit.
 - **Sportliche Aktivität:** vorhersagende/erklärende (Prädiktor-)Variable.
 - **Lebenszufriedenheit:** vorhergesagte/erklärte Variable.


Regression

- Im Gegensatz zur Korrelation bestimmt die Regression nicht die Linearität des Zusammenhangs (vielmehr wird dies vorausgesetzt), sondern die **Steigung** des Zusammenhangs.
- Aus diesem Grund ist die Regression (wieder im Gegensatz zur Korrelation) nicht symmetrisch – die Steigung ist abhängig davon welche Variable als abhängig oder Prädiktor deklariert wird.
 - Wie wir noch sehen werden, ist es auch nicht gestattet, die Regressionsgleichung zu invertieren ($x_i = \frac{1}{\hat{b}_1} \hat{y}_i - \frac{\hat{b}_0}{\hat{b}_1}$) – im Allgemeinen ist $\frac{1}{\hat{b}_1}$ *nicht* die Steigung, wenn die Rollen von X und Y vertauscht werden.
- Die Vorhersage/Erklärung von X durch Y geschieht durch eine Gleichung – die **Regressionsgleichung** – die im Streudiagramm als Gerade eingezeichnet werden kann.



Bestimmung der Regressionsgerade: Methode der kleinsten Quadrate


- Ziel der Regression ist es, die Gerade zu finden, die die Datenpunkte möglichst gut abbildet — es gibt jedoch verschiedene Definitionen dessen, was “möglichst gut” heißt.
- Die häufigste Variante ist die **Methode der kleinsten Quadrate**, bei der die Gerade so gewählt wird, dass die Summe der quadrierten **senkrechten Abstände** jedes Datenpunktes zur Geraden minimal ist.
 - Engl. *ordinary least square*
- Die **einfache Regression** mit nur einer Prädiktorvariablen hat zwei freie Parameter, um die Gerade an die Datenpunkte anzupassen (zu “fitten”):
 - y-Achsenabschnitt $\hat{b}_0$ (engl. *intercept*)
 - Steigung $\hat{b}_1$ (engl. *slope*)
- Die senkrechten Abstände der Datenpunkte von der gefitteten Geraden werden **Residuen** genannt.
- Exakt 0 wären die senkrechten Abstände nur, wenn alle Punkte auf einer perfekten Gerade liegen.



Warum weichen die Datenpunkte von einer Geraden ab?

Verschiedene Gründe:

- Variablen hängen überhaupt nicht zusammen
- Zusammenhang ist nichtlinear
- Einfluss von Störvariablen
- Messungenauigkeit



In der Psychologie gibt es (bis auf triviale Fälle) keine perfekten linearen Zusammenhänge, d.h. es verbleiben immer **Residuen** $\Delta \hat{y}_i$:


$$\text{Residuum: } \Delta \hat{y}_i = \hat{\epsilon}_i = \hat{y}_i - y_i$$



Residuum = Differenz von vorhergesagtem Wert $\hat{y}_i$ und tatsächlichem Wert y_i

Streudiagramm bei Regression

- in der Regel UV auf der x-Achse und AV auf der y-Achse




https://phet.colorado.edu/sims/html/least-squares-regression/latest/least-squares-regression_all.html?locale=de

Totale, erklärte und Residuenquadratsumme

- Die Methode der kleinsten Quadrate minimiert die **Residuenquadratsumme (SQR)**:

$$SQR = \sum (\hat{y}_i - y_i)^2 = \sum \hat{\epsilon}_i^2$$

- Diese lässt sich in Bezug setzen zur **totalen Quadratsumme (SQT)** und zur **erklärten Quadratsumme (SQE)**.



Totale Quadratsumme	$SQT = \sum (y_i - \bar{y})^2$	Abstandsquadrate der Datenpunkte y_i vom Mittelwert $\bar{y}$	Gesamte Variabilität der Daten y_i .
Erklärte Quadratsumme	$SQE = \sum (\hat{y}_i - \bar{y})^2$	Abstandsquadrate der Vorhersagen $\hat{y}_i$ vom Mittelwert $\bar{y}$	Variabilität, die durch das Regressionsmodell ($\hat{y}_i$) erklärt wird.
Residuen- quadratsumme	$SQR = \sum (\hat{y}_i - y_i)^2$	Abstandsquadrate der Vorhersagen $\hat{y}_i$ von den Datenpunkten y_i	Variabilität, die durch das Regressionsmodell ($\hat{y}_i$) <u>nicht</u> erklärt wird.
Es gilt			
$SQT = SQE + SQR$	Die totale Quadratsumme (SQT) ist die Summe aus der erklärten Quadratsumme (SQE) und der Residuenquadratsumme (SQR).		
$SQR = SQT - SQE$	Der Teil der Datenvarianz (SQT), der nicht durch das Modell erklärt wird (SQE), entspricht der Residuenquadratsumme (SQR).		

Bestimmtheitsmaß

- Das **Bestimmtheitsmaß** R^2 gibt an, wie gut die Datenpunkte durch die Regressionsgerade gefittet werden (“Anpassungsgüte”).
- Es gibt an, welcher Anteil der Datenvarianz $Var(Y)$ durch die Varianz der Vorhersage $Var(\hat{Y})$ erklärt wird..

$$R^2 = \frac{Var(\hat{Y})}{Var(Y)} = \frac{\sum (\hat{y}_i - \bar{y})^2}{\sum (y_i - \bar{y})^2} = \frac{SQE}{SQT}$$

- .. oder äquivalent, den Anteil der erklärten Quadratsumme an der totalen Quadratsumme.



Bei einer einfachen Regression gilt: $R^2 = \rho^2$ Siehe **Herleitung**.

Das Bestimmtheitsmaß ist bei einer einfachen Regression also identisch dem quadrierten Korrelationskoeffizienten zwischen den Variablen X und Y !




Beispiel

Lebenszufriedenheit und sportliche Aktivität haben eine Korrelation von $\rho = 0.8$.

⇒ Sportliche Aktivität erklärt $\rho^2 = 0.64 \hat{=} 64\%$ der Varianz von Lebenszufriedenheit (und umgekehrt).

Bestimmtheitsmaß



Beispiele für zwei Regressionen mit Bestimmtheitsmaß $R^2 = 98,92\%$ und $R^2 = 57,13\%$. Selbst das schwächere Beispiel mit $57,13$ wäre für typische Effekte in der Psychologie noch ein außerordentlich hoher Wert.²

- Das Bestimmtheitsmaß R^2 gibt an, wie gut sich die Variable Y mit einer linearen Gleichung basierend auf X vorhersagen lässt.
- Der Maximalwert von R^2 ist 1. In diesem Fall erklärt die lineare Gleichung in X die Daten Y perfekt.
- Da das Bestimmtheitsmaß R^2 angibt, welcher Anteil der Varianz in den Daten durch die lineare Gleichung erklärt wird, wird es manchmal in Prozent ausgedrückt (d.h. mit 100 multipliziert; wie im Bild links). Der Maximalwert von R^2 ist dann 100%.

Analytische Form der Regressionskoeffizienten (einfache Regression)

Die **Regressionskoeffizienten** b_0 (Achsenabschnitt) und b_1 (Steigung) lassen sich analytisch **herleiten**:

The diagram illustrates the analytical derivation of the regression coefficients b_0 and b_1 . It consists of two main parts, each with a label in a grey box and a corresponding formula with arrows pointing to its components.

Left part: A grey box labeled "Achsenabschnitt" (Intercept) points to the formula $\hat{b}_0 = \bar{y} - \hat{b}_1 \bar{x}$. Arrows from the terms in the formula point to labels: $\bar{y}$ is labeled "Mittelwert des Kriteriums (y)", $\hat{b}_1$ is labeled "Regressionskoeffizient", and $\bar{x}$ is labeled "Mittelwert des Prädiktors (x)".

Right part: A grey box labeled "Regressionskoeffizient" points to the formula $\hat{b}_1 = \frac{Cov(X, Y)}{Var(X)}$. Arrows from the terms in the formula point to labels: $Cov(X, Y)$ is labeled "Kovarianz der Variablen x und y", and $Var(X)$ is labeled "Varianz des Prädiktors (x)".

- Aus den Mittelwerten und der Kovarianz von X und Y , sowie der Varianz von X , lassen sich also die Regressionskoeffizienten vollständig bestimmen.
- Auch hier zeigt sich wieder die Asymmetrie der Regression: während bei der Formel für die Pearson-Korrelation $\hat{\rho}$ der symmetrische Ausdruck $\sigma_X \sigma_Y$ im Nenner steht, ist es beim Steigungskoeffizienten $\hat{b}_1$ lediglich die Varianz der Prädiktorvariable $Var(X)$.
- Wäre stattdessen Y die Prädiktorvariable, stünde $Var(Y)$ im Nenner, und $\hat{b}_1$ hätte i.d.R. einen anderen Wert.
 - Dies ist auch der Grund, weshalb die Regressionsgleichung nicht einfach invertiert werden darf:

$$\cancel{x_i} = \frac{1}{\hat{b}_1} \hat{y}_i - \frac{\hat{b}_0}{\hat{b}_1}$$

$\left(\text{.. und } \frac{1}{\hat{b}_1} \text{ im Allgemeinen **nicht** der Steigungskoeffizient für } Y \text{ als Prädiktorvariable ist.} \right)$

Zusammenhang Regression ↔ Korrelation

- Folgender Zusammenhang gilt zwischen der Steigung b_1 und dem Korrelationskoeffizienten r :

$$\hat{b}_1 = \frac{Cov(X, Y)}{Var(X)} = \frac{Cov(X, Y)}{\sigma_X^2} = \underbrace{\frac{\sigma_Y}{\sigma_X}}_1 \frac{Cov(X, Y)}{\sigma_X \sigma_X} = \frac{\sigma_Y}{\sigma_X} \underbrace{\frac{Cov(X, Y)}{\sigma_X \sigma_Y}}_{\hat{\rho}} = \frac{\sigma_Y}{\sigma_X} \hat{\rho}$$

- Es gilt also

$$\hat{b}_1 = \frac{\sigma_Y}{\sigma_X} \hat{\rho} \quad \text{bzw.} \quad \hat{\rho} = \frac{\sigma_X}{\sigma_Y} \hat{b}_1$$



Sind die Standardabweichungen σ_X und σ_Y bekannt, kann aus der Steigung $\hat{b}_1$ der Regression immer auch der Korrelationskoeffizient $\hat{\rho}$ bestimmt werden (und umgekehrt).

- Der Ausdruck $\frac{\sigma_X}{\sigma_Y} \hat{b}_1$ wird auch **standardisierter Regressionskoeffizient** $\hat{\beta}_1$ genannt:

$$\hat{\beta}_1 = \frac{\sigma_X}{\sigma_Y} \hat{b}_1$$

- Bei der einfachen Regression ist der standardisierte Regressionskoeffizient identisch mit dem Korrelationskoeffizienten: $\hat{\beta}_1 = \hat{\rho}$

Standardisierter Regressionskoeffizient

- Wie gesehen erhält man den **standardisierten Regressionskoeffizienten** $\hat{\beta}$ durch die Transformation $\hat{\beta}_1 = \frac{\sigma_X}{\sigma_Y} \hat{b}_1$.
- Im Gegensatz zu $\hat{b}_1$ ist $\hat{\beta}_1$ unabhängig von der Skalierung von X und Y (also z.B. ob die Einheit als *cm* oder *m* gewählt wurde) $\Rightarrow \hat{\beta}$ -Koeffizienten lassen sich besser zwischen verschiedenen Regressionen vergleichen.

Interpretation im Kontext der Regressionsgleichungen $\hat{Y} = \hat{b}_0 + \hat{b}_1 X$ bzw. $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$

$\hat{b}_1$ Veränderung von Y in Originaleinheiten bei einer Änderung von X um den Wert 1.

$\hat{\beta}_1$ Veränderung von Y in Standardabweichungen (σ_Y) bei einer Änderung von X um *eine* Standardabweichung σ_X .

- Wurden sowohl X als auch Y vor der Regression standardisiert, also $\sigma_X = \sigma_Y = 1$, so sind die Regressionskoeffizienten automatisch standardisiert:

$$\hat{\beta}_1 = \frac{\sigma_X}{\sigma_Y} \hat{b}_1 = \frac{1}{1} \hat{b}_1 = \hat{b}_1$$

Definition **Standardisierung einer Variable** X = Variable X durch Stichprobenstandardabweichung σ_X teilen. Für die Variable X gilt nach der Standardisierung $\sigma_X = 1$.

Intuition hinter der Regressionssteigung

- Die Formel für die Steigung bei der einfachen Regression

$$\hat{b}_1 = \frac{Cov(X, Y)}{Var(X)}$$

.. erinnert an die Formel der Korrelation, bei der die Kovarianz ebenfalls standardisiert wird (mit $\frac{1}{\sigma_X \sigma_Y}$)

- Der entscheidende Unterschied ist, dass bei der Korrelation eine Standardisierung bezüglich *beider* Variablen vorgenommen wird, bei der Regression aber nur bezüglich der *Prädiktorvariable*.
- In der Folge wird bei der Regression folgende Frage beantwortet:

Was ist die Auswirkung einer Änderung der Prädiktorvariable X um 1 (**einheitslos!**) auf die abhängige Variable Y (**in deren Rohwertseinheiten!**).

- Auch hier wird wieder deutlich, dass bei der Regression eine feste Rollenverteilung vorgenommen wird: nur die Prädiktorvariable wird standardisiert.
- Da die Steigung also von der Varianz der Prädiktorvariable abhängt, ist es nicht zulässig anzunehmen, dass $\frac{1}{\hat{b}_1}$ einfach die Steigung wäre, wenn Y die Prädiktorvariable und X die abhängige Variable ist. Für die umgekehrte Steigung müssten wir schließlich die Varianz von Y berücksichtigen!

Ausblick: Multiple Regression

- Gibt es mehr als eine **Prädiktorvariable**, handelt es sich nicht mehr um eine einfache Regression, sondern um eine **multiple Regression**:

$$\hat{Y} = \hat{b}_0 + \hat{b}_1 X_1 + \hat{b}_2 X_2 + \dots$$

Diagram illustrating the components of the multiple regression equation:

- $\hat{b}_0$: Konstante (Intercept)
- $\hat{b}_1$: Koeffizient für den ersten Prädiktor (Coefficient for the first predictor)
- $\hat{b}_2$: Koeffizient für den zweiten Prädiktor (Coefficient for the second predictor)
- X_1 : 1. Prädiktor (First predictor)
- X_2 : 2. Prädiktor (Second predictor)
- $\dots$: usw. (and so on)

- Jeder Prädiktor $X_1, X_2, \dots, X_n$ hat einen eigenen Regressionskoeffizienten $\hat{b}_1, \hat{b}_2, \dots, \hat{b}_n$
- Multiple Regression wird ausführlich in Statistik 2 behandelt.

“Formula Notation”: Formalisierung von Regressionsmodellen

- Da Regressionen heute ausschließlich mit dem Computer berechnet werden, hat sich eine eigene Sprache etabliert, um Regressionsmodelle zu definieren (bekannt als *Formula Notation*):

Diagram illustrating the components of the Formula Notation regression model:

$$DV \sim 1 + IV1 + IV2 + \dots \quad \longleftrightarrow \quad \hat{Y} = \hat{b}_0 + \hat{b}_1 X_1 + \hat{b}_2 X_2 + \dots$$

Labels and arrows in the diagram:

- Abhängige Variable (Dependent Variable)** points to DV .
- Trennt abhängige Variable und Prädiktoren** points to the tilde ($\sim$).
- y-Achsenabschnitt** points to the constant term 1 .
- Prädiktorvariablen (Predictors)** points to the terms $IV1 + IV2$.



- Der Ausdruck “ $DV \sim 1 + IV1 + IV2$ ” kann der Statistiksoftware als *String* übergeben werden; so wird definiert, welches Regressionsmodell gerechnet werden soll.
- $DV, IV1, IV2$ sind dabei die gewählten Variablennamen — beliebige Ausdrücke sind möglich



“satisfaction ~ 1 + physical_activity”

Dies wäre eine mögliche Definition unserer einfachen Regression mit sportlicher Aktivität als Prädiktor und Lebenszufriedenheit als abhängiger Variable.


Regression: Erklärung versus Vorhersage

	Erklärung	Vorhersage
Ziel	Zusammenhänge zwischen Variablen untersuchen: - Hängen die Variablen X und Y zusammen? - Ist der Zusammenhang positiv oder negativ? - Wie stark ist der Zusammenhang?	Wie gut kann Variable Y durch Variable X vorhergesagt werden?
Interessante Größe	Steigung $\hat{b}_1$	Bestimmtheitsmaß R^2
Visuelle Hervorhebung der interessanten Größe		
Beispiel	Regression von Lebenszufriedenheit auf sportliche Aktivität. Der Regressionskoeffizient sei $\hat{b}_1 = 0.5$. - Der Zusammenhang ist positiv. - Eine Erhöhung von sportlicher Aktivität um den Wert 1 führt im Schnitt zu einer Erhöhung der Lebenszufriedenheit um den Wert 0.5.	Regression von Lebenszufriedenheit auf sportliche Aktivität. Das Bestimmtheitsmaß sei $R^2 = 0.4$. - Sportliche Aktivität hat eine gute Vorhersagekraft für Lebenszufriedenheit. - Sportliche Aktivität erklärt 40% der Varianz von interindividueller Lebenszufriedenheit.

[[Zusammenfassung]]

- Die lineare Regression erweitert die Korrelation zu einer **Vorhersageanalyse**: wenn Variablen korrelieren, lässt sich eine Variable aus der anderen vorhersagen.
- Die Vorhersage basiert auf einer **Regressionsgerade**, die alle Datenpunkte so gut wie möglich repräsentiert.
- Die Regressionsgerade wird durch den **Achsenabschnitt** $\hat{b}_0$ und die **Steigung** $\hat{b}_1$ beschrieben.
- Die standardisierte Form des Steigungs-Koeffizienten wird **Beta** bzw. $\hat{\beta}_1$ genannt und ist identisch dem Korrelationskoeffizienten (bei einfacher Regression).
- Das **Bestimmtheitsmaß** R^2 bemisst die Vorhersagegenauigkeit der Regression.
- Die Regression kann sowohl der **Vorhersage** einer Variable Y auf Basis einer Variable X dienen, als auch der **Erklärung** bzw. Beschreibung eines Zusammenhangs von X und Y .

Sie führen nun eine Regressionsanalyse bezüglich des Zusammenhangs von TikTok-Online-Zeit und Entzündungswerten durch. Einmal mit TikTok-Online-Zeit und einmal mit Entzündungswerten als Prädiktorvariable:



Es zeigt sich, dass 1 Stunde zusätzlicher TikTok-Konsum mit einer Erhöhung des Entzündungsparameters um 0,043 verbunden ist. Umgekehrt ist eine Erhöhung des Entzündungswertes um 1 mit 4,04 Stunden — bzw. etwas praktikabler, eine Erhöhung des Entzündungswertes um 0,1 mit 0,404 Stunden (24 Minuten) — verbunden.

Diese “rohen” Effektstärken zeigen: es handelt sich um ein substantiellen Zusammenhang!

Bonuscontent

Herleitung der Regressionskoeffizienten

- Die Methode der kleinsten Quadrate entspricht der Minimierung der quadratischen Residuen:

$$SQR = \sum (\hat{y}_i - y_i)^2 = \sum \left(\hat{b}_0 + \hat{b}_1 x_i - y_i \right)^2 \stackrel{!}{=} \min$$

- Um das Minimum von SQR in Abhängigkeit von $\hat{b}_0$ und $\hat{b}_1$ zu finden, setzen wir die Ableitungen von SQR nach den Parametern gleich Null (Infinitesimalrechnung@Schule 😊)
- Zunächst leiten wir SQR nach $\hat{b}_0$ ab (Kettenregel):

$$\frac{dSQR}{d\hat{b}_0} = \sum 2 \left(\hat{b}_0 + \hat{b}_1 x_i - y_i \right) = 2n\hat{b}_0 + 2 \sum \left(\hat{b}_1 x_i - y_i \right) = 0$$

$$\longrightarrow \hat{b}_0 = \frac{1}{n} \sum \left(y_i - \hat{b}_1 x_i \right) = \frac{1}{n} \sum y_i - \frac{\hat{b}_1}{n} \sum x_i = \bar{y} - \hat{b}_1 \bar{x}$$

- ...jetzt benötigen wir noch $\hat{b}_1$

Herleitung der Regressionskoeffizienten

- SQR nach $\hat{b}_1$ ableiten und gleich Null setzen:

$$\frac{dSQR}{d\hat{b}_1} = \sum 2(\hat{b}_0 + \hat{b}_1 x_i - y_i)x_i = 2\hat{b}_0 \sum x_i + 2\hat{b}_1 \sum x_i^2 - 2 \sum x_i y_i = 0$$

$$\longrightarrow \hat{b}_1 = \frac{\sum x_i y_i}{\sum x_i^2} - \frac{\hat{b}_0 \sum x_i}{\sum x_i^2} \stackrel{(\hat{b}_0 \text{ einsetzen})}{=} \frac{\sum x_i y_i}{\sum x_i^2} - \frac{\bar{y} \sum x_i}{\sum x_i^2} + \hat{b}_1 \frac{\bar{x} \sum x_i}{\sum x_i^2}$$

- Alle $\hat{b}_1$ -Terme auf die linke Seite bringen und einige Umformungen vornehmen:

$$\hat{b}_1 - \hat{b}_1 \frac{\bar{x} \sum x_i}{\sum x_i^2} = \frac{\sum x_i y_i}{\sum x_i^2} - \frac{\bar{y} \sum x_i}{\sum x_i^2}$$

$$b_1 \left(1 - \frac{\bar{x} \sum x_i}{\sum x_i^2} \right) = \frac{\sum x_i y_i - \bar{y} \sum x_i}{\sum x_i^2}$$

$$b_1 \left(\frac{\sum x_i^2}{\sum x_i^2} - \frac{\bar{x} \sum x_i}{\sum x_i^2} \right) = \frac{\sum x_i y_i - \bar{y} \sum x_i}{\sum x_i^2}$$

$$\hat{b}_1 \frac{\sum x_i^2 - \bar{x} \sum x_i}{\sum x_i^2} = \frac{\sum x_i y_i - \bar{y} \sum x_i}{\sum x_i^2}$$

$$\longrightarrow \hat{b}_1 = \frac{\sum x_i^2}{\sum x_i^2 - \bar{x} \sum x_i} \frac{\sum x_i y_i - \bar{y} \sum x_i}{\sum x_i^2} = \frac{\sum x_i y_i - \bar{y} \sum x_i}{\sum x_i^2 - \bar{x} \sum x_i} \stackrel{(\sum x_i = n\bar{x})}{=} \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2} \stackrel{:n}{=} \frac{\frac{1}{n} \sum x_i y_i - \bar{x}\bar{y}}{\frac{1}{n} \sum x_i^2 - \bar{x}^2}$$

Herleitung der Regressionskoeffizienten

- Zwischenergebnis:

$$\hat{b}_1 = \frac{\frac{1}{n} \sum x_i y_i - \bar{x} \bar{y}}{\frac{1}{n} \sum x_i^2 - \bar{x}^2}$$

- Um zu erkennen, dass der Zähler der Kovarianz und der Nenner der Varianz entspricht, betrachten wir nochmal die Formeln der (Ko)Varianz:

$$\begin{aligned} Cov(X, Y) &= \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \sum (x_i y_i - x_i \bar{y} - y_i \bar{x} + \bar{x} \bar{y}) = \frac{1}{n} \sum x_i y_i - \bar{y} \frac{1}{n} \sum x_i - \bar{x} \frac{1}{n} \sum y_i + \bar{x} \bar{y} = \\ &\quad \left(\frac{1}{n} \sum x_i = \bar{x} \right) \frac{1}{n} \sum x_i y_i - \bar{y} \bar{x} - \bar{x} \bar{y} + \bar{x} \bar{y} = \frac{1}{n} \sum x_i y_i - \bar{x} \bar{y} \\ &\quad \left(\frac{1}{n} \sum y_i = \bar{y} \right) \end{aligned}$$

$$\begin{aligned} Var(X) &= \frac{1}{n} \sum (x_i - \bar{x})^2 = \frac{1}{n} \sum (x_i^2 - 2x_i \bar{x} + \bar{x}^2) = \frac{1}{n} \sum x_i^2 - 2\bar{x} \frac{1}{n} \sum x_i + \bar{x}^2 = \\ &\quad \left(\frac{1}{n} \sum x_i = \bar{x} \right) \frac{1}{n} \sum x_i^2 - 2\bar{x}^2 + \bar{x}^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2 \end{aligned}$$

- Es gilt also tatsächlich:

$$b_1 = \frac{Cov(X, Y)}{Var(X)}$$

Beweis, dass $R^2 = \hat{\rho}^2$ bei einfacher Regression

- Ausgestattet mit der Formel für den Regressionskoeffizienten, lässt sich nun auch beweisen, dass bei der einfachen Regression gilt: $R^2 = \hat{\rho}^2$

$$\begin{aligned}
 R^2 &= \frac{Var(\hat{Y})}{Var(Y)} = \frac{\frac{1}{n} \sum (\hat{y}_i - \bar{y})^2}{Var(Y)} \stackrel{\substack{(\hat{y}_i = \hat{b}_0 + \hat{b}_1 x_i) \\ (\bar{y} = \hat{b}_0 + \hat{b}_1 \bar{x})}}{=} \frac{\frac{1}{n} \sum [(\hat{b}_0 + \hat{b}_1 x_i) - (\hat{b}_0 + \hat{b}_1 \bar{x})]^2}{Var(Y)} = \frac{\frac{1}{n} \sum (\hat{b}_1 x_i - \hat{b}_1 \bar{x})^2}{Var(Y)} \\
 &= \hat{b}_1^2 \frac{\frac{1}{n} \sum (x_i - \bar{x})^2}{Var(Y)} = \hat{b}_1^2 \frac{Var(X)}{Var(Y)} \quad \left(\text{NB sieht man, dass gilt: } Var(\hat{Y}) = \hat{b}_1^2 Var(X) \right)
 \end{aligned}$$

- Nun $\hat{b}_1 = \frac{Cov(X,Y)}{Var(X)}$ einsetzen:

$$R^2 = \frac{Cov^2(X,Y)}{Var^2(X)} \frac{Var(X)}{Var(Y)} = \frac{Cov^2(X,Y)}{Var(X)Var(Y)}$$

- Vergleiche mit $\hat{\rho}^2$:

$$\hat{\rho}^2 = \left[\frac{Cov(X,Y)}{\sigma_X \sigma_Y} \right]^2 = \frac{Cov^2(X,Y)}{\sigma_X^2 \sigma_Y^2} = \frac{Cov^2(X,Y)}{Var(X)Var(Y)}$$

Fußnoten

1. <https://flowingdata.com/2014/06/25/duck-vs-rabbit-plot/>
2. <https://de.wikipedia.org/wiki/Datei:R2values.svg>