


M24 Statistik 1: Sommersemester 2025

# Vorlesung 05: Regression

Prof. Matthias Guggenmos  
Health and Medical University Potsdam




Kurze Erinnerung: beim letzten Mal fanden wir einen Zusammenhang von TikTok-Online-Zeit und Entzündungsparametern:



Bei der Interpretation stellt sich einerseits die Kausalitätsfrage, andererseits, wie stark der Zusammenhang tatsächlich ist. Da die Pearson-Korrelation lediglich den **Grad der Linearität** beurteilt, fragen Sie sich: um wie viel erhöhen sich die Entzündungsparameter pro Stunde zusätzliche Zeit auf TikTok? Oder umgekehrt: um wie viel erhöht sich die Zeit auf TikTok, wenn die Entzündungswerte um einen Wert x ansteigen?


# Regression



Bildnachweis<sup>1</sup>

# Regression



- Dem Wortsinn nach ist Ziel der **Regression** eine abhängige Variable auf eine oder mehrere Prädiktorvariablen zurückzuführen (auf diese zu *regredieren*).
- Eingängiger ist aber die umgekehrte Formulierung: Ziel der Regression ist es, auf Basis der Prädiktorvariablen die abhängige Variable **vorherzusagen** oder **zu erklären**:
  - Prädiktorvariable(n) = *vorhersagende* oder *erklärende* Variable(n).
  - Abhängige Variable = *vorhergesagte* oder *erklärte* Variable.



- Beispiel: Studie untersucht Auswirkung von sportlicher Aktivität auf Lebenszufriedenheit.
  - **Sportliche Aktivität:** vorhersagende/erklärende (Prädiktor-)Variable.
  - **Lebenszufriedenheit:** vorhergesagte/erklärte Variable.


# Regression

- Im Gegensatz zur Korrelation bestimmt die Regression nicht die Linearität des Zusammenhangs (vielmehr wird dies vorausgesetzt), sondern die **Steigung** des Zusammenhangs.
- Aus diesem Grund ist die Regression (wieder im Gegensatz zur Korrelation) nicht symmetrisch – die Steigung ist abhängig davon welche Variable als abhängig oder Prädiktor deklariert wird.
  - Wie wir noch sehen werden, ist es auch nicht gestattet, die Regressionsgleichung zu invertieren ( $x_i = \frac{1}{\hat{b}_1} \hat{y}_i - \frac{\hat{b}_0}{\hat{b}_1}$ ) – im Allgemeinen ist  $\frac{1}{\hat{b}_1}$  *nicht* die Steigung, wenn die Rollen von  $X$  und  $Y$  vertauscht werden.
- Die Vorhersage/Erklärung von  $X$  durch  $Y$  geschieht durch eine Gleichung – die **Regressionsgleichung** – die im Streudiagramm als Gerade eingezeichnet werden kann.



# Bestimmung der Regressionsgerade: Methode der kleinsten Quadrate


- Ziel der Regression ist es, die Gerade zu finden, die die Datenpunkte möglichst gut abbildet — es gibt jedoch verschiedene Definitionen dessen, was “möglichst gut” heißt.
- Die häufigste Variante ist die **Methode der kleinsten Quadrate**, bei der die Gerade so gewählt wird, dass die Summe der quadrierten **senkrechten Abstände** jedes Datenpunktes zur Geraden minimal ist.
  - Engl. *ordinary least square*
- Die **einfache Regression** mit nur einer Prädiktorvariablen hat zwei freie Parameter, um die Gerade an die Datenpunkte anzupassen (zu “fitten”):
  - y-Achsenabschnitt  $\hat{b}_0$  (engl. *intercept*)
  - Steigung  $\hat{b}_1$  (engl. *slope*)
- Die senkrechten Abstände der Datenpunkte von der gefitteten Geraden werden **Residuen** genannt.
- Exakt 0 wären die senkrechten Abstände nur, wenn alle Punkte auf einer perfekten Gerade liegen.



# Warum weichen die Datenpunkte von einer Geraden ab?

Verschiedene Gründe:

- Variablen hängen überhaupt nicht zusammen
- Zusammenhang ist nichtlinear
- Einfluss von Störvariablen
- Messungenauigkeit



In der Psychologie gibt es (bis auf triviale Fälle) keine perfekten linearen Zusammenhänge, d.h. es verbleiben immer **Residuen**  $\Delta\hat{y}_i$ :


$$\text{Residuum: } \Delta\hat{y}_i = \hat{\epsilon}_i = \hat{y}_i - y_i$$



Residuum = Differenz von vorhergesagtem Wert  $\hat{y}_i$  und tatsächlichem Wert  $y_i$


# Streudiagramm bei Regression

- in der Regel UV auf der x-Achse und AV auf der y-Achse





[https://phet.colorado.edu/sims/html/least-squares-regression/latest/least-squares-regression\\_all.html?locale=de](https://phet.colorado.edu/sims/html/least-squares-regression/latest/least-squares-regression_all.html?locale=de)




# Totale, erklärte und Residuenquadratsumme

- Die Methode der kleinsten Quadrate minimiert die **Residuenquadratsumme (SQR)**:

$$SQR = \sum (\hat{y}_i - y_i)^2 = \sum \hat{\epsilon}_i^2$$

- Diese lässt sich in Bezug setzen zur **totalen Quadratsumme (SQT)** und zur **erklärten Quadratsumme (SQE)**.



|                           |                                                                                                                            |                                                                              |                                                                                             |
|---------------------------|----------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|
| Totale<br>Quadratsumme    | $SQT = \sum (y_i - \bar{y})^2$                                                                                             | Abstandsquadrate der<br>Datenpunkte $y_i$ vom Mittelwert<br>$\bar{y}$        | Gesamte Variabilität der Daten $y_i$ .                                                      |
| Erklärte<br>Quadratsumme  | $SQE = \sum (\hat{y}_i - \bar{y})^2$                                                                                       | Abstandsquadrate der Vorhersa-<br>gen $\hat{y}_i$ vom Mittelwert $\bar{y}$   | Variabilität, die durch das Regressions-<br>modell $(\hat{y}_i)$ erklärt wird.              |
| Residuen-<br>quadratsumme | $SQR = \sum (\hat{y}_i - y_i)^2$                                                                                           | Abstandsquadrate der Vorhersa-<br>gen $\hat{y}_i$ von den Datenpunkten $y_i$ | Variabilität, die durch das Regressions-<br>modell $(\hat{y}_i)$ <u>nicht</u> erklärt wird. |
| Es gilt                   |                                                                                                                            |                                                                              |                                                                                             |
| $SQT = SQE + SQR$         | Die totale Quadratsumme (SQT) ist die Summe aus der erklärten Quadratsumme (SQE) und der Residuenquadratsumme (SQR).       |                                                                              |                                                                                             |
| $SQR = SQT - SQE$         | Der Teil der Datenvarianz (SQT), der nicht durch das Modell erklärt wird (SQE), entspricht der Residuenquadratsumme (SQR). |                                                                              |                                                                                             |

# Bestimmtheitsmaß

- Das **Bestimmtheitsmaß**  $R^2$  gibt an, wie gut die Datenpunkte durch die Regressionsgerade gefittet werden (“Anpassungsgüte”).
- Es gibt an, welcher Anteil der Datenvarianz  $Var(Y)$  durch die Varianz der Vorhersage  $Var(\hat{Y})$  erklärt wird..

$$R^2 = \frac{Var(\hat{Y})}{Var(Y)} = \frac{\sum (\hat{y}_i - \bar{y})^2}{\sum (y_i - \bar{y})^2} = \frac{SQE}{SQT}$$

- .. oder äquivalent, den Anteil der erklärten Quadratsumme an der totalen Quadratsumme.



Bei einer einfachen Regression gilt:  $R^2 = \hat{\rho}^2$  Siehe **Herleitung**.

Das Bestimmtheitsmaß ist bei einer einfachen Regression also identisch dem quadrierten Korrelationskoeffizienten zwischen den Variablen  $X$  und  $Y$ !




**Beispiel**

Lebenszufriedenheit und sportliche Aktivität haben eine Korrelation von  $\hat{\rho} = 0.8$ .

⇒ Sportliche Aktivität erklärt  $\hat{\rho}^2 = 0.64 \hat{=} 64\%$  der Varianz von Lebenszufriedenheit (und umgekehrt).

# Bestimmtheitsmaß



Beispiele für zwei Regressionen mit Bestimmtheitsmaß  $R^2 = 98,92\%$  und  $R^2 = 57,13\%$ . Selbst das schwächere Beispiel mit  $57,13$  wäre für typische Effekte in der Psychologie noch ein außerordentlich hoher Wert.<sup>2</sup>

- Das Bestimmtheitsmaß  $R^2$  gibt an, wie gut sich die Variable  $Y$  mit einer linearen Gleichung basierend auf  $X$  vorhersagen lässt.
- Der Maximalwert von  $R^2$  ist 1. In diesem Fall erklärt die lineare Gleichung in  $X$  die Daten  $Y$  perfekt.
- Da das Bestimmtheitsmaß  $R^2$  angibt, welcher Anteil der Varianz in den Daten durch die lineare Gleichung erklärt wird, wird es manchmal in Prozent ausgedrückt (d.h. mit 100 multipliziert; wie im Bild links). Der Maximalwert von  $R^2$  ist dann 100%.

# Analytische Form der Regressionskoeffizienten (einfache Regression)

Die **Regressionskoeffizienten**  $\hat{b}_0$  (Achsenabschnitt) und  $\hat{b}_1$  (Steigung) lassen sich analytisch **herleiten**:

$$\begin{array}{l} \text{Achsenabschnitt} \rightarrow \hat{b}_0 = \bar{y} - \hat{b}_1 \bar{x} \\ \begin{array}{l} \text{Regressionskoeffizient} \leftarrow \hat{b}_1 \\ \text{Mittelwert des Prädiktors (x)} \leftarrow \bar{x} \\ \text{Mittelwert des Kriteriums (y)} \leftarrow \bar{y} \end{array} \end{array} \quad \begin{array}{l} \text{Regressionskoeffizient} \rightarrow \hat{b}_1 = \frac{\hat{Cov}(X, Y)}{\hat{Var}(X)} \\ \begin{array}{l} \text{Kovarianz der Variablen x und y} \leftarrow \hat{Cov}(X, Y) \\ \text{Varianz des Prädiktors (x)} \leftarrow \hat{Var}(X) \end{array} \end{array}$$

- Aus den Mittelwerten und der Kovarianz von  $X$  und  $Y$ , sowie der Varianz von  $X$ , lassen sich also die Regressionskoeffizienten vollständig bestimmen.
- Auch hier zeigt sich wieder die Asymmetrie der Regression: während bei der Formel für die Pearson-Korrelation  $\hat{\rho}$  der symmetrische Ausdruck  $\hat{\sigma}_X \hat{\sigma}_Y$  im Nenner steht, ist es beim Steigungskoeffizienten  $\hat{b}_1$  lediglich die Varianz der Prädiktorvariable  $\hat{Var}(X)$ .
- Wäre stattdessen  $Y$  die Prädiktorvariable, stünde  $\hat{Var}(Y)$  im Nenner, und  $\hat{b}_1$  hätte i.d.R. einen anderen Wert.
  - Dies ist auch der Grund, weshalb die Regressionsgleichung nicht einfach invertiert werden darf:

~~$$x_i = \frac{1}{\hat{b}_1} \hat{y}_i - \frac{\hat{b}_0}{\hat{b}_1}$$~~

(.. und  $\frac{1}{\hat{b}_1}$  im Allgemeinen **nicht** der Steigungskoeffizient für  $Y$  als Prädiktorvariable ist.)

# Zusammenhang Regression ↔ Korrelation

- Folgender Zusammenhang gilt zwischen der Steigung  $b_1$  und dem Korrelationskoeffizienten  $r$ :

$$\hat{b}_1 = \frac{\hat{Cov}(X, Y)}{\hat{Var}(X)} = \frac{\hat{Cov}(X, Y)}{\hat{\sigma}_X^2} = \underbrace{\frac{\hat{\sigma}_Y}{\hat{\sigma}_X}}_1 \frac{\hat{Cov}(X, Y)}{\hat{\sigma}_X \hat{\sigma}_X} = \frac{\hat{\sigma}_Y}{\hat{\sigma}_X} \underbrace{\frac{\hat{Cov}(X, Y)}{\hat{\sigma}_X \hat{\sigma}_Y}}_{\hat{\rho}} = \frac{\hat{\sigma}_Y}{\hat{\sigma}_X} \hat{\rho}$$

- Es gilt also

$$\hat{b}_1 = \frac{\hat{\sigma}_Y}{\hat{\sigma}_X} \hat{\rho} \quad \text{bzw.} \quad \hat{\rho} = \frac{\hat{\sigma}_X}{\hat{\sigma}_Y} \hat{b}_1$$



Sind die Standardabweichungen  $\hat{\sigma}_X$  und  $\hat{\sigma}_Y$  bekannt, kann aus der Steigung  $\hat{b}_1$  der Regression immer auch der Korrelationskoeffizient  $\hat{\rho}$  bestimmt werden (und umgekehrt).

- Der Ausdruck  $\frac{\hat{\sigma}_X}{\hat{\sigma}_Y} \hat{b}_1$  wird auch **standardisierter Regressionskoeffizient**  $\hat{\beta}_1$  genannt:

$$\hat{\beta}_1 = \frac{\hat{\sigma}_X}{\hat{\sigma}_Y} \hat{b}_1$$

- Bei der einfachen Regression ist der standardisierte Regressionskoeffizient identisch mit dem Korrelationskoeffizienten:  $\hat{\beta}_1 = \hat{\rho}$

# Standardisierter Regressionskoeffizient

- Wie gesehen erhält man den **standardisierten Regressionskoeffizienten**  $\hat{\beta}$  durch die Transformation  $\hat{\beta}_1 = \frac{\hat{\sigma}_X}{\hat{\sigma}_Y} \hat{b}_1$ .
- Im Gegensatz zu  $\hat{b}_1$  ist  $\hat{\beta}_1$  unabhängig von der Skalierung von  $X$  und  $Y$  (also z.B. ob die Einheit als *cm* oder *m* gewählt wurde)  $\Rightarrow \hat{\beta}$ -Koeffizienten lassen sich besser zwischen verschiedenen Regressionen vergleichen.

Interpretation im Kontext der Regressionsgleichungen  $\hat{Y} = \hat{b}_0 + \hat{b}_1 X$  bzw.  $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$

$\hat{b}_1$  Veränderung von  $Y$  in Origineleinheiten bei einer Änderung von  $X$  um den Wert 1.

$\hat{\beta}_1$  Veränderung von  $Y$  in Standardabweichungen ( $\hat{\sigma}_Y$ ) bei einer Änderung von  $X$  um *eine* Standardabweichung  $\hat{\sigma}_X$ .

- Wurden sowohl  $X$  als auch  $Y$  vor der Regression standardisiert, also  $\sigma_X = \sigma_Y = 1$ , so sind die Regressionskoeffizienten automatisch standardisiert:

$$\hat{\beta}_1 = \frac{\hat{\sigma}_X}{\hat{\sigma}_Y} \hat{b}_1 \quad (\hat{\sigma} = \sqrt{\frac{n-1}{n}} \sigma) \quad \frac{\sqrt{\frac{n-1}{n}} \sigma_X}{\sqrt{\frac{n-1}{n}} \sigma_Y} \hat{b}_1 = \frac{\sigma_X}{\sigma_Y} \hat{b}_1 = \frac{1}{1} \hat{b}_1 = \hat{b}_1$$

Zur Erinnerung: die Standardisierung basiert auf der Stichprobenstandardabweichung (ohne  $\wedge$ ).

# Intuition hinter der Regressionssteigung

- Die Formel für die Steigung bei der einfachen Regression

$$\hat{b}_1 = \frac{\hat{Cov}(X, Y)}{\hat{Var}(X)}$$

.. erinnert an die Formel der Korrelation, bei der die Kovarianz ebenfalls standardisiert wird (mit  $\frac{1}{\hat{\sigma}_X \hat{\sigma}_Y}$ )

- Der entscheidende Unterschied ist, dass bei der Korrelation eine Standardisierung bezüglich *beider* Variablen vorgenommen wird, bei der Regression aber nur bezüglich der *Prädiktorvariable*.
- In der Folge wird bei der Regression folgende Frage beantwortet:

Was ist die Auswirkung einer Änderung der Prädiktorvariable  $X$  um 1 (**einheitslos!**) auf die abhängige Variable  $Y$  (**in deren Rohwertseinheiten!**).

- Auch hier wird wieder deutlich, dass bei der Regression eine feste Rollenverteilung vorgenommen wird: nur die Prädiktorvariable wird standardisiert.
- Da die Steigung also von der Varianz der Prädiktorvariable abhängt, ist es nicht zulässig anzunehmen, dass  $\frac{1}{\hat{b}_1}$  einfach die Steigung wäre, wenn  $Y$  die Prädiktorvariable und  $X$  die abhängige Variable ist. Für die umgekehrte Steigung müssten wir schließlich die Varianz von  $Y$  berücksichtigen!



# Ausblick: Multiple Regression

- Gibt es mehr als eine **Prädiktorvariable**, handelt es sich nicht mehr um eine einfache Regression, sondern um eine **multiple Regression**:

$$\hat{Y} = \hat{b}_0 + \hat{b}_1 X_1 + \hat{b}_2 X_2 + \dots$$

Diagram illustrating the components of the multiple regression equation:

- $\hat{b}_0$ : Konstante (Intercept)
- $\hat{b}_1$ : Koeffizient für den ersten Prädiktor (Coefficient for the first predictor)
- $\hat{b}_2$ : Koeffizient für den zweiten Prädiktor (Coefficient for the second predictor)
- $X_1$ : 1. Prädiktor (First predictor)
- $X_2$ : 2. Prädiktor (Second predictor)
- $\dots$ : usw. (and so on)

- Jeder Prädiktor  $X_1, X_2, \dots, X_n$  hat einen eigenen Regressionskoeffizienten  $\hat{b}_1, \hat{b}_2, \dots, \hat{b}_n$
- Multiple Regression wird ausführlich in Statistik 2 behandelt.

# “Formula Notation”: Formalisierung von Regressionsmodellen

- Da Regressionen heute ausschließlich mit dem Computer berechnet werden, hat sich eine eigene Sprache etabliert, um Regressionsmodelle zu definieren (bekannt als *Formula Notation*):

$$DV \sim 1 + P1 + P2 + \dots \longleftrightarrow \hat{Y} = \hat{b}_0 + \hat{b}_1 X_1 + \hat{b}_2 X_2 + \dots$$

Annotations:

- y-Achsenabschnitt (points to 1 and  $\hat{b}_0$ )
- Prädiktorvariablen (Predictors) (points to P1 and P2)
- Trennt abhängige Variable und Prädiktoren (points to  $\sim$ )
- Abhängige Variable (Dependent Variable) (points to DV)



- Der Ausdruck “DV ~ 1 + P1 + P2” kann der Statistiksoftware als *String* übergeben werden; so wird definiert, welches Regressionsmodell gerechnet werden soll.
- DV, P1, P2 sind dabei die gewählten Variablennamen — beliebige Ausdrücke sind möglich



“satisfaction ~ 1 + physical\_activity”

Dies wäre eine mögliche Definition unserer einfachen Regression mit sportlicher Aktivität als Prädiktor und Lebenszufriedenheit als abhängiger Variable.


# Regression: Erklärung versus Vorhersage

|                                               | Erklärung                                                                                                                                                                                                                                                                                                                                                       | Vorhersage                                                                                                                                                                                                                                                                                                                                               |
|-----------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Ziel                                          | <p>Zusammenhänge zwischen Variablen untersuchen:</p> <ul style="list-style-type: none"> <li>- Hängen die Variablen <math>X</math> und <math>Y</math> zusammen?</li> <li>- Ist der Zusammenhang positiv oder negativ?</li> <li>- Wie stark ist der Zusammenhang?</li> </ul>                                                                                      | <p>Wie gut kann Variable <math>Y</math> durch Variable <math>X</math> vorhergesagt werden?</p>                                                                                                                                                                                                                                                           |
| Interessante Größe                            | Steigung $\hat{b}_1$                                                                                                                                                                                                                                                                                                                                            | Bestimmtheitsmaß $R^2$                                                                                                                                                                                                                                                                                                                                   |
| Visuelle Hervorhebung der interessanten Größe |                                                                                                                                                                                                                                                                               |                                                                                                                                                                                                                                                                       |
| Beispiel                                      | <p>Regression von Lebenszufriedenheit auf sportliche Aktivität. Der Regressionskoeffizient sei <math>\hat{b}_1 = 0.5</math>.</p> <ul style="list-style-type: none"> <li>- Der Zusammenhang ist positiv.</li> <li>- Eine Erhöhung von sportlicher Aktivität um den Wert 1 führt im Schnitt zu einer Erhöhung der Lebenszufriedenheit um den Wert 0.5.</li> </ul> | <p>Regression von Lebenszufriedenheit auf sportliche Aktivität. Das Bestimmtheitsmaß sei <math>R^2 = 0.4</math>.</p> <ul style="list-style-type: none"> <li>- Sportliche Aktivität hat eine gute Vorhersagekraft für Lebenszufriedenheit.</li> <li>- Sportliche Aktivität erklärt 40% der Varianz von interindividueller Lebenszufriedenheit.</li> </ul> |

# [[ Zusammenfassung ]]

- Die lineare Regression erweitert die Korrelation zu einer **Vorhersageanalyse**: wenn Variablen korrelieren, lässt sich eine Variable aus der anderen vorhersagen.
- Die Vorhersage basiert auf einer **Regressionsgerade**, die alle Datenpunkte so gut wie möglich repräsentiert.
- Die Regressionsgerade wird durch den **Achsenabschnitt**  $\hat{b}_0$  und die **Steigung**  $\hat{b}_1$  beschrieben.
- Die standardisierte Form des Steigungs-Koeffizienten wird **Beta** bzw.  $\hat{\beta}_1$  genannt und ist identisch dem Korrelationskoeffizienten (bei einfacher Regression).
- Das **Bestimmtheitsmaß**  $R^2$  bemisst die Vorhersagegenauigkeit der Regression.
- Die Regression kann sowohl der **Vorhersage** einer Variable  $Y$  auf Basis einer Variable  $X$  dienen, als auch der **Erklärung** bzw. Beschreibung eines Zusammenhangs von  $X$  und  $Y$ .

Sie führen nun eine Regressionsanalyse bezüglich des Zusammenhangs von TikTok-Online-Zeit und Entzündungswerten durch. Einmal mit TikTok-Online-Zeit und einmal mit Entzündungswerten als Prädiktorvariable:



Es zeigt sich, dass 1 Stunde zusätzlicher TikTok-Konsum mit einer Erhöhung des Entzündungsparameters um 0,043 verbunden ist. Umgekehrt ist eine Erhöhung des Entzündungswertes um 1 mit 4,04 Stunden — bzw. etwas praktikabler, eine Erhöhung des Entzündungswertes um 0,1 mit 0,404 Stunden (24 Minuten) — verbunden.

Diese “rohen” Effektstärken zeigen: es handelt sich um ein substantiellen Zusammenhang!

# Bonuscontent

# Herleitung der Regressionskoeffizienten

- Die Methode der kleinsten Quadrate entspricht der Minimierung der quadratischen Residuen:

$$SQR = \sum (\hat{y}_i - y_i)^2 = \sum \left( \hat{b}_0 + \hat{b}_1 x_i - y_i \right)^2 \stackrel{!}{=} \min$$

- Um das Minimum von SQR in Abhängigkeit von  $\hat{b}_0$  und  $\hat{b}_1$  zu finden, setzen wir die Ableitungen von SQR nach den Parametern gleich Null (Infinitesimalrechnung@Schule 😊)
- Zunächst leiten wir SQR nach  $\hat{b}_0$  ab (Kettenregel):

$$\frac{dSQR}{d\hat{b}_0} = \sum 2 \left( \hat{b}_0 + \hat{b}_1 x_i - y_i \right) = 2n\hat{b}_0 + 2 \sum \left( \hat{b}_1 x_i - y_i \right) = 0$$

$$\longrightarrow \hat{b}_0 = \frac{1}{n} \sum \left( y_i - \hat{b}_1 x_i \right) = \frac{1}{n} \sum y_i - \frac{\hat{b}_1}{n} \sum x_i = \bar{y} - \hat{b}_1 \bar{x}$$

- ...jetzt benötigen wir noch  $\hat{b}_1$

# Herleitung der Regressionskoeffizienten

- SQR nach  $\hat{b}_1$  ableiten und gleich Null setzen:

$$\frac{dSQR}{d\hat{b}_1} = \sum 2(\hat{b}_0 + \hat{b}_1 x_i - y_i)x_i = 2\hat{b}_0 \sum x_i + 2\hat{b}_1 \sum x_i^2 - 2 \sum x_i y_i = 0$$

$$\longrightarrow \hat{b}_1 = \frac{\sum x_i y_i}{\sum x_i^2} - \frac{\hat{b}_0 \sum x_i}{\sum x_i^2} \stackrel{(\hat{b}_0 \text{ einsetzen})}{=} \frac{\sum x_i y_i}{\sum x_i^2} - \frac{\bar{y} \sum x_i}{\sum x_i^2} + \hat{b}_1 \frac{\bar{x} \sum x_i}{\sum x_i^2}$$

- Alle  $\hat{b}_1$ -Terme auf die linke Seite bringen und einige Umformungen vornehmen:

$$\hat{b}_1 - \hat{b}_1 \frac{\bar{x} \sum x_i}{\sum x_i^2} = \frac{\sum x_i y_i}{\sum x_i^2} - \frac{\bar{y} \sum x_i}{\sum x_i^2}$$

$$b_1 \left( 1 - \frac{\bar{x} \sum x_i}{\sum x_i^2} \right) = \frac{\sum x_i y_i - \bar{y} \sum x_i}{\sum x_i^2}$$

$$b_1 \left( \frac{\sum x_i^2}{\sum x_i^2} - \frac{\bar{x} \sum x_i}{\sum x_i^2} \right) = \frac{\sum x_i y_i - \bar{y} \sum x_i}{\sum x_i^2}$$

$$\hat{b}_1 \frac{\sum x_i^2 - \bar{x} \sum x_i}{\sum x_i^2} = \frac{\sum x_i y_i - \bar{y} \sum x_i}{\sum x_i^2}$$

$$\longrightarrow \hat{b}_1 = \frac{\sum x_i^2}{\sum x_i^2 - \bar{x} \sum x_i} \frac{\sum x_i y_i - \bar{y} \sum x_i}{\sum x_i^2} = \frac{\sum x_i y_i - \bar{y} \sum x_i}{\sum x_i^2 - \bar{x} \sum x_i} \stackrel{(\sum x_i = n\bar{x})}{=} \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2} \stackrel{:n}{=} \frac{\frac{1}{n} \sum x_i y_i - \bar{x}\bar{y}}{\frac{1}{n} \sum x_i^2 - \bar{x}^2}$$



# Herleitung der Regressionskoeffizienten

- Zwischenergebnis:

$$\hat{b}_1 = \frac{\frac{1}{n} \sum x_i y_i - \bar{x} \bar{y}}{\frac{1}{n} \sum x_i^2 - \bar{x}^2}$$

- Um zu erkennen, dass der Zähler der Kovarianz und der Nenner der Varianz entspricht, betrachten wir nochmal die Formeln der (Ko)Varianz:

$$\begin{aligned} Cov(X, Y) &= \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \sum (x_i y_i - x_i \bar{y} - y_i \bar{x} + \bar{x} \bar{y}) = \frac{1}{n} \sum x_i y_i - \bar{y} \frac{1}{n} \sum x_i - \bar{x} \frac{1}{n} \sum y_i + \bar{x} \bar{y} = \\ &\quad \left( \frac{1}{n} \sum x_i = \bar{x} \right) \frac{1}{n} \sum x_i y_i - \bar{y} \bar{x} - \bar{x} \bar{y} + \bar{x} \bar{y} = \frac{1}{n} \sum x_i y_i - \bar{x} \bar{y} \\ &\quad \left( \frac{1}{n} \sum y_i = \bar{y} \right) \end{aligned}$$

$$\begin{aligned} Var(X) &= \frac{1}{n} \sum (x_i - \bar{x})^2 = \frac{1}{n} \sum (x_i^2 - 2x_i \bar{x} + \bar{x}^2) = \frac{1}{n} \sum x_i^2 - 2\bar{x} \frac{1}{n} \sum x_i + \bar{x}^2 = \\ &\quad \left( \frac{1}{n} \sum x_i = \bar{x} \right) \frac{1}{n} \sum x_i^2 - 2\bar{x}^2 + \bar{x}^2 = \frac{1}{n} \sum x_i^2 - \bar{x}^2 \end{aligned}$$

- Es gilt also tatsächlich:

$$b_1 = \frac{Cov(X, Y)}{Var(X)} \stackrel{\text{(identisch)}}{=} \frac{\hat{Cov}(X, Y)}{\hat{Var}(X)}$$

# Beweis, dass $R^2 = \hat{\rho}^2$ bei einfacher Regression

- Ausgestattet mit der Formel für den Regressionskoeffizienten, lässt sich nun auch beweisen, dass bei der einfachen Regression gilt:  $R^2 = \hat{\rho}^2$

$$\begin{aligned}
 R^2 &= \frac{\text{Var}(\hat{Y})}{\text{Var}(Y)} = \frac{\frac{1}{n} \sum (\hat{y}_i - \bar{y})^2}{\text{Var}(Y)} \stackrel{\substack{(\hat{y}_i = \hat{b}_0 + \hat{b}_1 x_i) \\ (\bar{y} = \hat{b}_0 + \hat{b}_1 \bar{x})}}{=} \frac{\frac{1}{n} \sum [(\hat{b}_0 + \hat{b}_1 x_i) - (\hat{b}_0 + \hat{b}_1 \bar{x})]^2}{\text{Var}(Y)} = \frac{\frac{1}{n} \sum (\hat{b}_1 x_i - \hat{b}_1 \bar{x})^2}{\text{Var}(Y)} \\
 &= \hat{b}_1^2 \frac{\frac{1}{n} \sum (x_i - \bar{x})^2}{\text{Var}(Y)} = \hat{b}_1^2 \frac{\text{Var}(X)}{\text{Var}(Y)} \quad \left( \text{NB sieht man, dass gilt: } \text{Var}(\hat{Y}) = \hat{b}_1^2 \text{Var}(X) \right)
 \end{aligned}$$

- Nun  $\hat{b}_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$  einsetzen:

$$R^2 = \frac{\text{Cov}^2(X, Y)}{\text{Var}^2(X)} \frac{\text{Var}(X)}{\text{Var}(Y)} = \frac{\text{Cov}^2(X, Y)}{\text{Var}(X) \text{Var}(Y)}$$

- Vergleiche mit  $\hat{\rho}^2$ :

$$\hat{\rho}^2 = \left[ \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \right]^2 = \frac{\text{Cov}^2(X, Y)}{\sigma_X^2 \sigma_Y^2} = \frac{\text{Cov}^2(X, Y)}{\text{Var}(X) \text{Var}(Y)}$$

# Fußnoten

1. <https://flowingdata.com/2014/06/25/duck-vs-rabbit-plot/>
2. <https://de.wikipedia.org/wiki/Datei:R2values.svg>